

RELATÓRIO TÉCNICO

INTEGRANTES: Gustavo Marques de Lanna & João Vitor Umetsu Kusaka

EMPRESA ESCOLHIDA: Aliexpress

PRODUTO ESCOLHIDO: Teclado e Mouse Raiku T26

1 – INTRODUÇÃO

O comércio eletrônico atual lida diariamente com um volume massivo de avaliações e comentários deixados por clientes, tornando a leitura e análise manual dessas informações uma tarefa inviável para as equipes de suporte e gestão de produtos. Essa dificuldade impede que a empresa identifique rapidamente falhas de qualidade, insatisfações ou pontos fortes em seu catálogo. Para solucionar esse problema, este estudo de caso tem como objetivo principal o desenvolvimento e a aplicação de técnicas de Processamento de Linguagem Natural (PLN) para automatizar a análise de sentimentos de avaliações de consumidores. Utilizando um conjunto de dados reais coletados na plataforma AliExpress referentes ao Kit Teclado e Mouse - RAIKU T26, o sistema classifica automaticamente os feedbacks em categorias positivas, negativas ou neutras, além de extrair palavras-chave essenciais para auxiliar a tomada de decisão da empresa.

2 - REFERENCIAL TEÓRICO

O Processamento de Linguagem Natural (PLN) é uma subárea da Inteligência Artificial que capacita computadores a compreender, interpretar e manipular a linguagem humana. No contexto de mineração de textos em e-commerce, as etapas fundamentais compreendem:

Pré-processamento e Limpeza de Texto: Etapa crucial para eliminar ruídos dos dados textuais, como pontuações, caracteres especiais, números e formatações indesejadas que não agregam valor preditivo.

Remoção de Palavras Irrelevantes (Stop Words): Filtro de termos altamente frequentes na língua (como artigos, preposições, conjunções e pronomes — ex: "de", "para", "o", "e", "que") que não carregam significado semântico relevante para a análise de sentimento.

Tokenização: Processo de fragmentação do texto corrido em unidades menores chamadas tokens, geralmente correspondendo às palavras individuais do comentário.

Análise de Sentimentos: Metodologia computacional voltada à identificação da polaridade emocional expressa em um texto. Neste trabalho, a polaridade foi estipulada com base nas notas (estrelas) atribuídas pelos compradores: 1 a 2 estrelas (negativo), 3 estrelas (neutro) e 4 a 5 estrelas (positivo).

3 – METODOLOGIA

O desenvolvimento da solução de Processamento de Linguagem Natural (PLN) seguiu um pipeline estruturado de engenharia de dados textuais dividido nas seguintes etapas:

Coleta e Amostragem de Dados: Foram coletadas um total de 25 avaliações reais de clientes na página do Kit Teclado e Mouse - RAIKU T26 no AliExpress, contemplando de forma equilibrada as faixas de pontuação de 1 a 5 estrelas.

Rotulagem de Sentimentos: As avaliações foram mapeadas em classes de polaridade conforme a regra estabelecida: avaliações de 1 a 2 estrelas foram rotuladas como negativas, 3 estrelas como neutras, e de 4 a 5 estrelas como positivas.

Pré-processamento e Limpeza Textual: O texto bruto passou por rotinas automatizadas em Python para a remoção sequencial de ruídos. Inicialmente, o corpus total contava com 1101 tokens. As etapas de limpeza consistiram em:

- **Remoção de Artigos:** Eliminação de determinantes e artigos definidos/indefinidos, reduzindo a base para 1018 tokens.
- **Remoção de Pontuação e Números:** Exclusão de caracteres especiais, sinais de pontuação e dígitos numéricos isolados, diminuindo o quantitativo para 839 e posteriormente 833 tokens.

- **Remoção de Stop Words:** Filtragem de palavras irrelevantes ao contexto semântico (como preposições, conjunções e pronomes de alta frequência), resultando em 491 tokens essenciais.
- **Normalização (Lematização e Radicalização):** Os termos remanescentes passaram por processos de lematização e stemming (radicalização) para unificar variações flexionais e extrair os radicais comuns das palavras.
- **Divisão da Base de Dados (Holdout Estratificado):** A base tratada contendo os termos e os rótulos de polaridade foi dividida em conjuntos de treinamento e teste utilizando a técnica de holdout estratificado, garantindo a preservação proporcional das classes em ambas as partições.

4 - RESULTADOS

A aplicação do script de pré-processamento sobre as 25 avaliações do produto gerou reduções significativas e métricas importantes para a análise:

Redução Dimensional do Vocabulário: O pipeline executado demonstrou alta eficiência na limpeza de dados, enxugando o corpus textual bruto de 1101 tokens para 491 tokens otimizados, eliminando os ruídos que poderiam comprometer a classificação automática.

Comportamento do Pipeline (Exemplo Prático):

Texto Original (Ex: Avaliação 13): "O produto chegou em uma caixa amassada. O mouse está quebrada em algumas partes..."

Após Limpeza e Radicalização: ['produt', 'cheg', 'caix', 'amass', 'mous', 'quebr', 'algum', 'part']

Identificação de Temas e Palavras-Chave:

Nos comentários positivos, destacaram-se termos voltados à satisfação e desempenho, tais como rápido, confortável, ótimo, custo-benefício e silencioso. Nos comentários negativos e neutros, o modelo isolou termos recorrentes associados a falhas de fabricação e problemas logísticos, como quebr, caix, amass, mous, barat e desconect.

Impacto Gerencial: Com a base tratada e estruturada, o sistema demonstrou capacidade de automatizar a triagem de feedbacks do e-commerce, permitindo que a empresa identifique rapidamente gargalos de transporte internacional e insatisfações com a qualidade dos materiais do teclado do AliExpress.

5 - CONCLUSÃO

O desenvolvimento deste estudo de caso permitiu aplicar de maneira prática os conceitos teóricos fundamentais de Processamento de Linguagem Natural (PLN). A partir de um cenário real de e-commerce utilizando as avaliações de um produto do AliExpress (Kit Teclado e Mouse - RAIKU T26), foi possível automatizar todo o pipeline de engenharia de dados textuais. Constatou-se que etapas como limpeza de texto, remoção de stop words e tokenização são essenciais para transformar dados não estruturados (comentários brutos) em uma base tratada e apta para algoritmos de classificação. A solução demonstra grande utilidade gerencial, pois capacita empresas a mapearem de forma rápida e automatizada a satisfação dos consumidores, identificando gargalos logísticos e de fabricação com precisão.